

Examen – MLOPS ET DEPLOIEMENT

Projet : Implémentation et déploiement d'un modèle de scoring (détaillé)

Contexte du projet :

Dans un environnement professionnel où les données jouent un rôle central, les entreprises cherchent à automatiser la prise de décision grâce à des modèles de machine learning fiables et déployables. Le secteur visé peut être la finance, le marketing, la santé, ou tout autre domaine où il est crucial de prédire avec précision une classe binaire (par exemple : risque de défaut de paiement, probabilité d'achat, présence d'une maladie).

Le but de ce projet est de vous faire expérimenter le cycle complet du développement d'un modèle de scoring : de la préparation des données à la mise en production, en passant par la définition d'un score métier qui reflète les enjeux réels (faux positifs vs faux négatifs).

Vous apprendrez à gérer le versioning des modèles via MLFlow, à sélectionner et optimiser vos algorithmes, puis à déployer une API accessible dans le cloud. Vous réaliserez également une interface utilisateur simple pour tester votre modèle, et aborderez la notion cruciale de surveillance continue, avec l'analyse du data drift, afin de garantir la pertinence du modèle dans le temps.

Ce projet s'inscrit dans une démarche MLOps complète, alliant sciences des données et ingénierie logicielle, indispensable pour industrialiser les modèles et faciliter leur adoption en entreprise.

Étape 1 : Préparation de l'environnement MLFlow

- Installez MLFlow localement ou sur un serveur cloud.
- Configurez un backend de suivi (par exemple, une base de données PostgreSQL ou un serveur distant).
- Testez la journalisation d'une expérience simple (paramètres, métriques, artefacts).
- Vérifiez que vous pouvez visualiser les résultats via l'interface MLFlow.

Étape 2 : Préparation et traitement des données

- Choisissez un Kernel Kaggle adapté à une classification binaire avec un bon travail de feature engineering.
- Importez et nettoyez les données (traitement des valeurs manquantes, suppression des outliers, etc.).
- Effectuez des transformations et créez de nouvelles features si nécessaire.
- Séparez les données en ensembles d'entraînement et de test.

Étape 3 : Définition du score métier

- Analysez les coûts relatifs entre faux positifs et faux négatifs selon le contexte métier (par exemple, risque financier ou satisfaction client).
- Proposez une fonction de scoring qui pondère ces erreurs de manière appropriée.
- Intégrez ce score dans l'évaluation de vos modèles.

Étape 4 : Entraînement et comparaison de modèles

- Sélectionnez plusieurs algorithmes de classification (ex. logistic regression, random forest, XGBoost).
- Utilisez GridSearchCV pour optimiser les hyperparamètres.
- Appliquez des techniques de gestion du déséquilibre (sur-/sous-échantillonnage, SMOTE, ou ajustement des poids).
- Calculez la feature importance et analysez la pertinence des variables (Lime, Shape etc)
- Comparez vos modèles entre eux et à une baseline simple.

Étape 5 : Déploiement de l'API de scoring

- Créez une API REST avec FastAPI ou Flask qui reçoit des données, prédit le score, et renvoie la réponse.
- Mettez le code sous contrôle de version avec Git (branche principale, commits clairs).
- Déployez l'API sur un service cloud (ex. Heroku, AWS, GCP).
- Configurez une pipeline CI/CD avec Github Actions pour automatiser les déploiements.

Étape 6 : Interface avec Streamlit

- Développez une application Streamlit simple où l'utilisateur peut saisir manuellement des données.
- Intégrez un appel à l'API pour afficher les résultats en temps réel.
- Ajoutez des visualisations ou messages pour faciliter la compréhension des résultats.

Étape 7 : Analyse du data drift et préparation à la soutenance

- Définissez des indicateurs à monitorer pour détecter un changement dans la distribution des données.
- Proposez une stratégie de réentraînement ou d'alerte en cas de dérive.
- Préparez un support de présentation clair regroupant objectifs, méthodes, résultats et perspectives.

AIDARA CHAMSEDINE

Tech Lead Data & IA